

ПЕРВОЕ ВЫСШЕЕ ТЕХНИЧЕСКОЕ УЧЕБНОЕ ЗАВЕДЕНИЕ РОССИИ



**МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ
ФЕДЕРАЦИИ**

**федеральное государственное бюджетное образовательное учреждение высшего
образования**

**САНКТ-ПЕТЕРБУРГСКИЙ ГОРНЫЙ УНИВЕРСИТЕТ ИМПЕРАТРИЦЫ
ЕКАТЕРИНЫ II**

Кафедра информатики и компьютерных технологий

ПРАКТИЧЕСКАЯ РАБОТА №4

По дисциплине: Практические навыки и опыт анализа данных с помощью

Python

(наименование учебной дисциплины согласно учебному плану)

Тема работы: Разведочный анализ данных

Выполнил: студент гр.

ИТ-25-3 (ИАС-25-1)
(шифр группы)

(подпись)

Черников В.М.
(Ф.И.О.)

Оценка: _____

Дата: _____

Проверил

руководитель работы:

доцент
(должность)

(подпись)

Кочнева А.А.
(Ф.И.О.)

Санкт-Петербург 2026

Введение

В современном мире объемы данных растут экспоненциально, и способность извлекать из них осмысленную информацию становится ключевой компетенцией аналитика. Прежде чем строить сложные модели машинного обучения или делать статистические выводы, необходимо глубоко понять структуру данных, выявить скрытые закономерности, обнаружить аномалии и сформулировать гипотезы. Именно для этого применяется разведочный анализ данных (Exploratory Data Analysis, EDA) — подход, предложенный Джоном Тьюки, который ставит во главу угла визуализацию и описательную статистику как основные инструменты исследования.

Целью данной практической работы является освоение методов разведочного анализа данных, формирование навыков исследования наборов данных, выявления в них скрытых закономерностей, обнаружения аномальных значений и определения структурных особенностей с использованием современных библиотек языка Python.

Этап 1

Повторим и проанализируем код, представленный в задании (см. Рисунку 1 – 4):

```
[1] 1 import pandas as pd
2
3 dataset = pd.read_csv('movies.csv')
4 dataset.head()

... Показать скрытые выходные данные
Далее: New interactive sheet

[2] 1 # Оценка размеров датасета
2 dataset.shape
3 # Результат: (5000, 11)
4
5 # Информация о датасете
6 dataset.info()
7
8 # Проверка дубликатов
9 dataset.duplicated().sum()
10 # Результат: 0

... Показать скрытые выходные данные

... Анализ пропусков

[3] 1 dataset['gross_earn'].isna().sum()
np.int64(415)

[9] 1 dataset['runtime'].unique()
2
3 import re
4
5 def clear_runtime(parameter) runtime: Any
6     if 'min' in runtime:
7         return int(re.sub(r'\D', '', runtime))
8     else:
9         return 0
10
11 # Применение функции
12 dataset['runtime_clean'] = dataset['runtime'].apply(clear_runtime)
13

... Очистка признака gross_earn

[10] 1 import numpy as np
2
3 def clear_gross_earn(gross_earn):
4     if pd.isna(gross_earn):
5         return np.nan
6     else:
7         return re.sub(r'[\$M]', '', gross_earn)
8
9 # Применение функции
10 dataset['gross_earn_clean'] = dataset['gross_earn'].apply(clear_gross_earn)
11 dataset['gross_earn_clean'] = pd.to_numeric(dataset['gross_earn_clean'])

... Сортировка и сохранение

[11] 1 # Сортировка по рейтингу (убывание)
2 sorted_dataset = dataset.sort_values('rating', ascending=False)
3 sorted_dataset.reset_index(drop=True, inplace=True)
4
5 # Сохранение
6 sorted_dataset.to_csv('movies_clean.csv')
7
8 # Перезагрузка очищенного датасета
9 dataset = pd.read_csv('movies_clean.csv')
10 dataset.drop(columns='Unnamed: 0', inplace=True)
```

Рисунок 1 – Google colab

```

АНАЛИЗ КОЛИЧЕСТВЕННЫХ ПРИЗНАКОВ

Статистический анализ признака gross_earn_clear

16] 1 gross_earn = dataset['gross_earn_clear']
2
3 max_value = gross_earn.max()
4 min_value = gross_earn.min()
5 print('Наибольший доход:', max_value, 'Наименьший доход:', min_value)

Наибольший доход: 936.66 Наименьший доход: 0.0

17] 1 # Анализ наблюдений с доходом 0.0
2 dataset[dataset['gross_earn_clear'] == 0.0]
3
4 # Исключение нулей из анализа
5 gross_earn = dataset[dataset['gross_earn_clear'] != 0.0]['gross_earn_clear']

21] 1 max_value = gross_earn.max()
2 min_value = gross_earn.min()
3 print('Наибольший доход: ', max_value, 'Наименьший доход: ', min_value)

Наибольший доход: 936.66 Наименьший доход: 0.01

22] 1 median_value = gross_earn.median()
2 print('Медиана доходов фильмов: ', median_value)

Медиана доходов фильмов: 28.235

23] 1 percentile_10_value = gross_earn.quantile(0.10)
2 percentile_25_value = gross_earn.quantile(0.25)
3 percentile_50_value = gross_earn.quantile(0.50)
4 percentile_75_value = gross_earn.quantile(0.75)
5 percentile_90_value = gross_earn.quantile(0.90)
6 print('10-й процентиль доходов фильмов: ', percentile_10_value)
7 print('25-й процентиль доходов фильмов: ', percentile_25_value)
8 print('50-й процентиль доходов фильмов: ', percentile_50_value)
9 print('75-й процентиль доходов фильмов: ', percentile_75_value)
10 print('90-й процентиль доходов фильмов: ', percentile_90_value)

10-й процентиль доходов фильмов: 0.78
25-й процентиль доходов фильмов: 6.9875
50-й процентиль доходов фильмов: 28.235
75-й процентиль доходов фильмов: 62.665
90-й процентиль доходов фильмов: 121.77500000000005

24] 1 gross_earn.describe()

Показать скрытые выходные данные

25] 1 import matplotlib.pyplot as plt

26] 1 plt.boxplot(gross_earn)
2 plt.show()

Показать скрытые выходные данные

27] 1 plt.hist(gross_earn)
2 plt.show()

Показать скрытые выходные данные

28] 1 gross_earn_2 = dataset[
2 (dataset['gross_earn_clear'] >= percentile_10_value) &
3 (dataset['gross_earn_clear'] <= percentile_90_value)]['gross_earn_clear']
4 plt.boxplot(gross_earn_2)
5 plt.show()

... Показать скрытые выходные данные

29] 1 plt.hist(gross_earn_2, bins = 20)
2 plt.show()

... Показать скрытые выходные данные

31] 1 dataset['certificate'].describe()

array(['15', 'X', '12A', 'U', '18', '12', 'PG', 'A', 'R', 'AA',
'Not Rated', '144 min', 'Rejected', '137 min', '170 min', '87 min',
'102 min', 'UA', '99 min', '142 min', '140 min', 'PG-13',
'112 min', '116 min', '124 min', '97 min', '100 min', '107 min',
'119 min', '106 min', '(Banned)', '90 min', '103 min', '104 min',
'98 min', '93 min', '89 min', '114 min', '70 min'], dtype=object)

```

Рисунок 2 – Google colab

```
[32] 1 dataset['certificate'].unique()
✓ 0 сек.
> Показать скрытые выходные данные

[37] 1 dataset['certificate'].value_counts()
✓ 0 сек. 2 certificate_counts = dataset['certificate'].value_counts().sort_values(ascending=True)

[39] 1 plt.barh(certificate_counts.index, certificate_counts.values)
✓ 0 сек. 2 plt.title('Столбчатая диаграмма распределения фильмов по классам')
3 plt.show()
> Показать скрытые выходные данные

[40] 1 certificate_counts_top_5 = dataset['certificate'].value_counts()[:5]
✓ 0 сек.

[41] 1 plt.pie(certificate_counts_top_5.values, labels =
✓ 0 сек. 2 certificate_counts_top_5.index, autopct='%1.1f')
3 plt.show()
> Показать скрытые выходные данные

[42] 1 import seaborn as sns
✓ 2 сек. 2 sns.jointplot(x=dataset["runtime_clear"],
3 y=dataset["gross_earn_clear"], size=10, alpha=0.2)
4 plt.show()
> ... Показать скрытые выходные данные

[43] 1 columns = ['runtime_clear', 'gross_earn_clear']
✓ 0 сек. 2 g = sns.PairGrid(dataset[columns])
3 g.map(sns.scatterplot, alpha=0.2)
> Показать скрытые выходные данные

[49] 1 new_dataset = dataset
✓ 0 сек. 2 for col in columns:
3 limiter = new_dataset[col].quantile(0.99)
4 new_dataset = new_dataset[new_dataset[col]<=limiter]
5
6 g = sns.PairGrid(new_dataset[columns])
7 g.map(sns.scatterplot, alpha=0.2)
> ... Показать скрытые выходные данные

[50] 1 directors = dataset['director'].unique()
✓ 0 сек. 2 len(directors)
1969

[51] 1 dataset['director'].value_counts()
✓ 0 сек.
> Показать скрытые выходные данные

[52] 1 directors_top_5 = dataset['director'].value_counts()[:5].index
✓ 0 сек.

[53] 1 labels = dataset['certificate'].unique()
✓ 0 сек. 2 colors = dict(zip(labels, plt.cm.tab20.colors[:len(labels)]))
3 colors
> Показать скрытые выходные данные

[58] 1 for director in directors_top_5:
✓ 0 сек. 2 df = dataset[dataset['director'] == director]
3 certificate_counts = df['certificate'].value_counts()
4 labels = certificate_counts.index
5 plt.title(director)
6 try:
7 plt.pie(certificate_counts.values, labels = labels, colors = [colors[key] for key in labels])
8 plt.show()
9 except Exception:
10 pass
> Показать скрытые выходные данные

[62] 1 dataset.groupby('certificate')['gross_earn_clear'].median()
✓ 0 сек. 2 dataset.groupby('certificate')['gross_earn_clear'].describe()
> Показать скрытые выходные данные

[63] 1 sns.boxplot(x='certificate', y="gross_earn_clear", data = dataset)
✓ 1 сек.
> Показать скрытые выходные данные

[64] 1 dataset['certificate'].value_counts()
✓ 0 сек.
> Показать скрытые выходные данные
```

Рисунок 3 – Google colab

```
[66] 1 certificate_list = dataset['certificate'].value_counts()[:8].index
✓ 0 2 certificate_list
сек.

... Index(['15', '12A', '18', 'P6', 'U', '12', 'A', 'X'], dtype='object', name='certificate')

[68] 1 dataset_certificate_top_8 = dataset[dataset['certificate'].isin(certificate_list)]
✓ 0
сек.

[72] 1 sns.boxplot(x='certificate', y="gross_earn_clear", data =
✓ 0 2 dataset_certificate_top_8)
сек. 3 plt.axis(ymin=0, ymax=700)

> ... Показать скрытые выходные данные
```

Рисунок 4 – Google colab

Этап 2

Основной целью данного задания является проведение разведочного анализа данных для выявления основных паттернов и отношений между переменными, а также предобработка данных для дальнейшего анализа(см. Рисунку 5 – 12):

```
Импорт библиотек

[75] 1 import pandas as pd
✓ 0 2 import numpy as np
сек. 3 import matplotlib.pyplot as plt
4 import seaborn as sns

Загрузка данных

Чтобы изменить содержимое ячейки, дважды нажмите на нее (или выберите "Ввод")

[77] 1 heart_data = pd.read_csv('heart_disease_data.csv')
✓ 0
сек.

Первичный осмотр данных

[81] 1 print("Размер датасета:", heart_data.shape)
✓ 0 2 print("\nИнформация о датасете:")
сек. 3 heart_data.info()
4 print("\nПроверка дубликатов:", heart_data.duplicated().sum())
5 print("\nПроверка пропусков:\n", heart_data.isna().sum())

... Показать скрытые выходные данные

[80] 1 # Удаляем дубликаты
✓ 0 2 heart_data = heart_data.drop_duplicates()
сек. 3
4 # Проверяем результат
5 print("Размер после удаления дубликатов:", heart_data.shape)
6 print("Осталось дубликатов:", heart_data.duplicated().sum())

Размер после удаления дубликатов: (302, 14)
Осталось дубликатов: 0
```

Рисунок 5 – Подготовка




Рисунок 6 – Описательная статистика и анализ целевой переменной



Рисунок 7 – Анализ количественных признаков

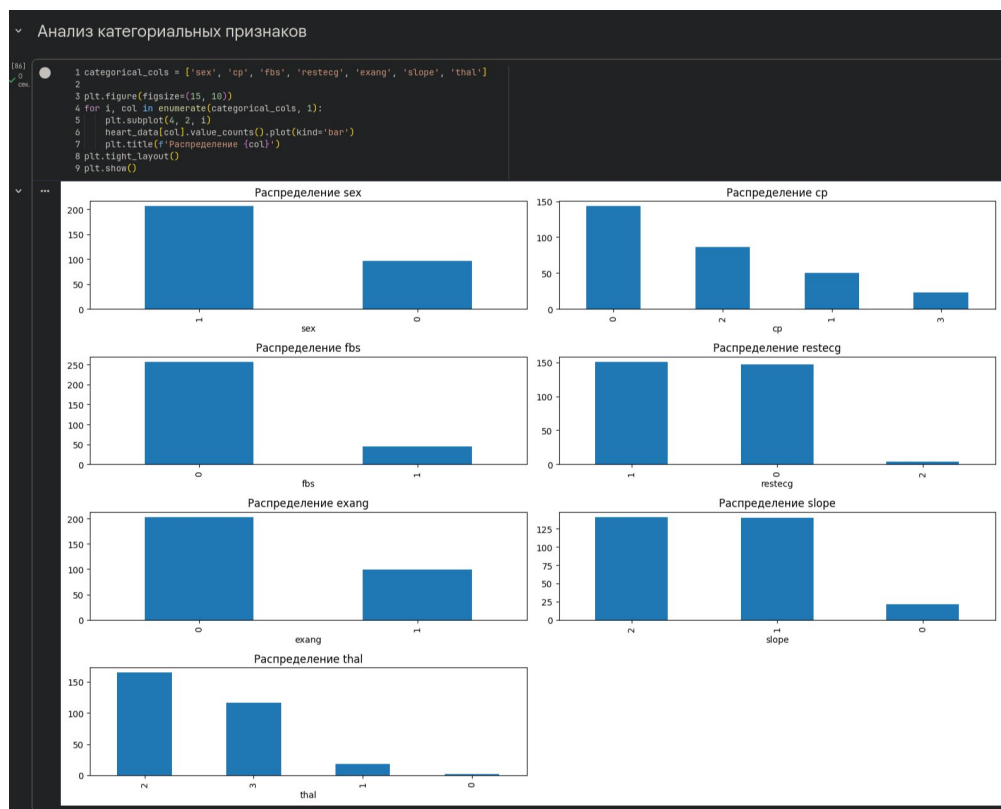


Рисунок 8 – Анализ категориальных признаков

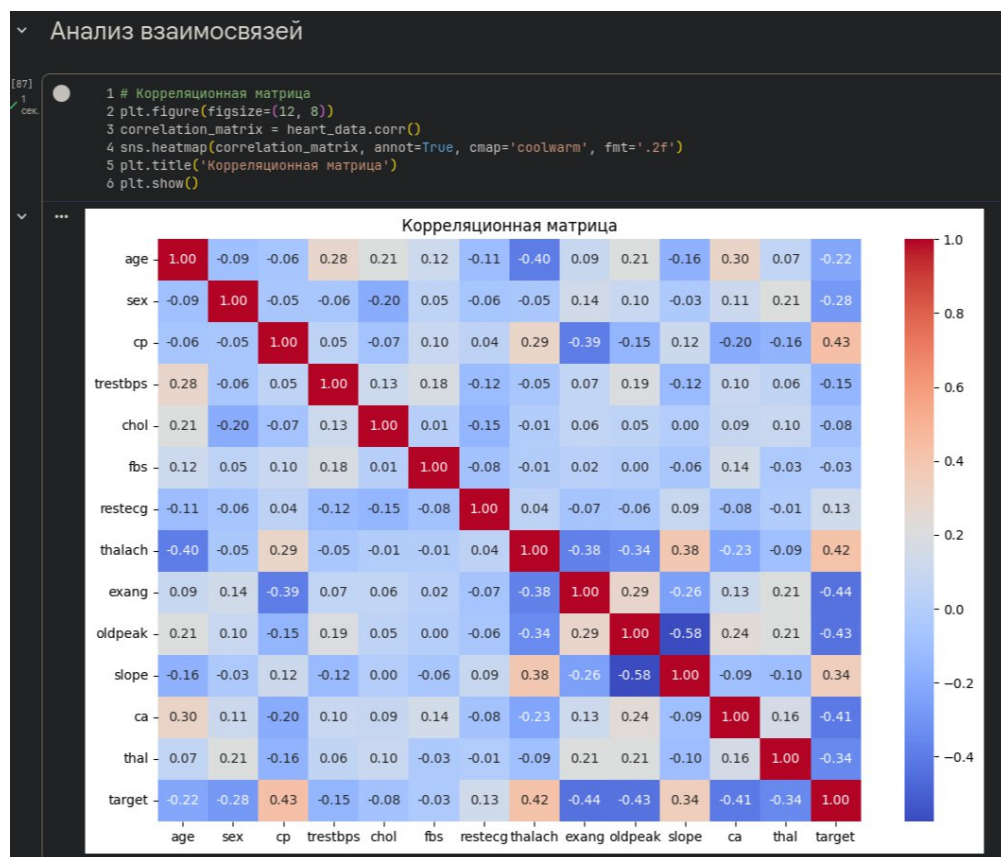


Рисунок 9 – Анализ взаимосвязей

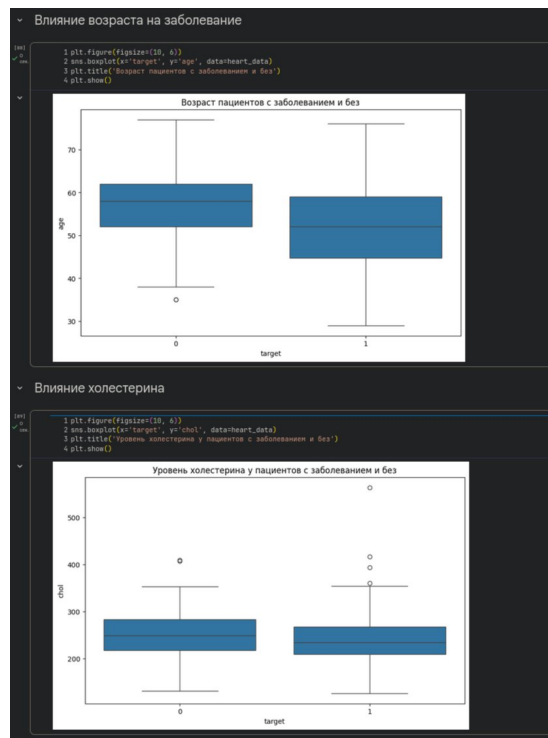


Рисунок 10 – Влияние возраста на заболевание; Влияние холестерина



Рисунок 11 – Совместное распределение age и thalach; Анализ по полу

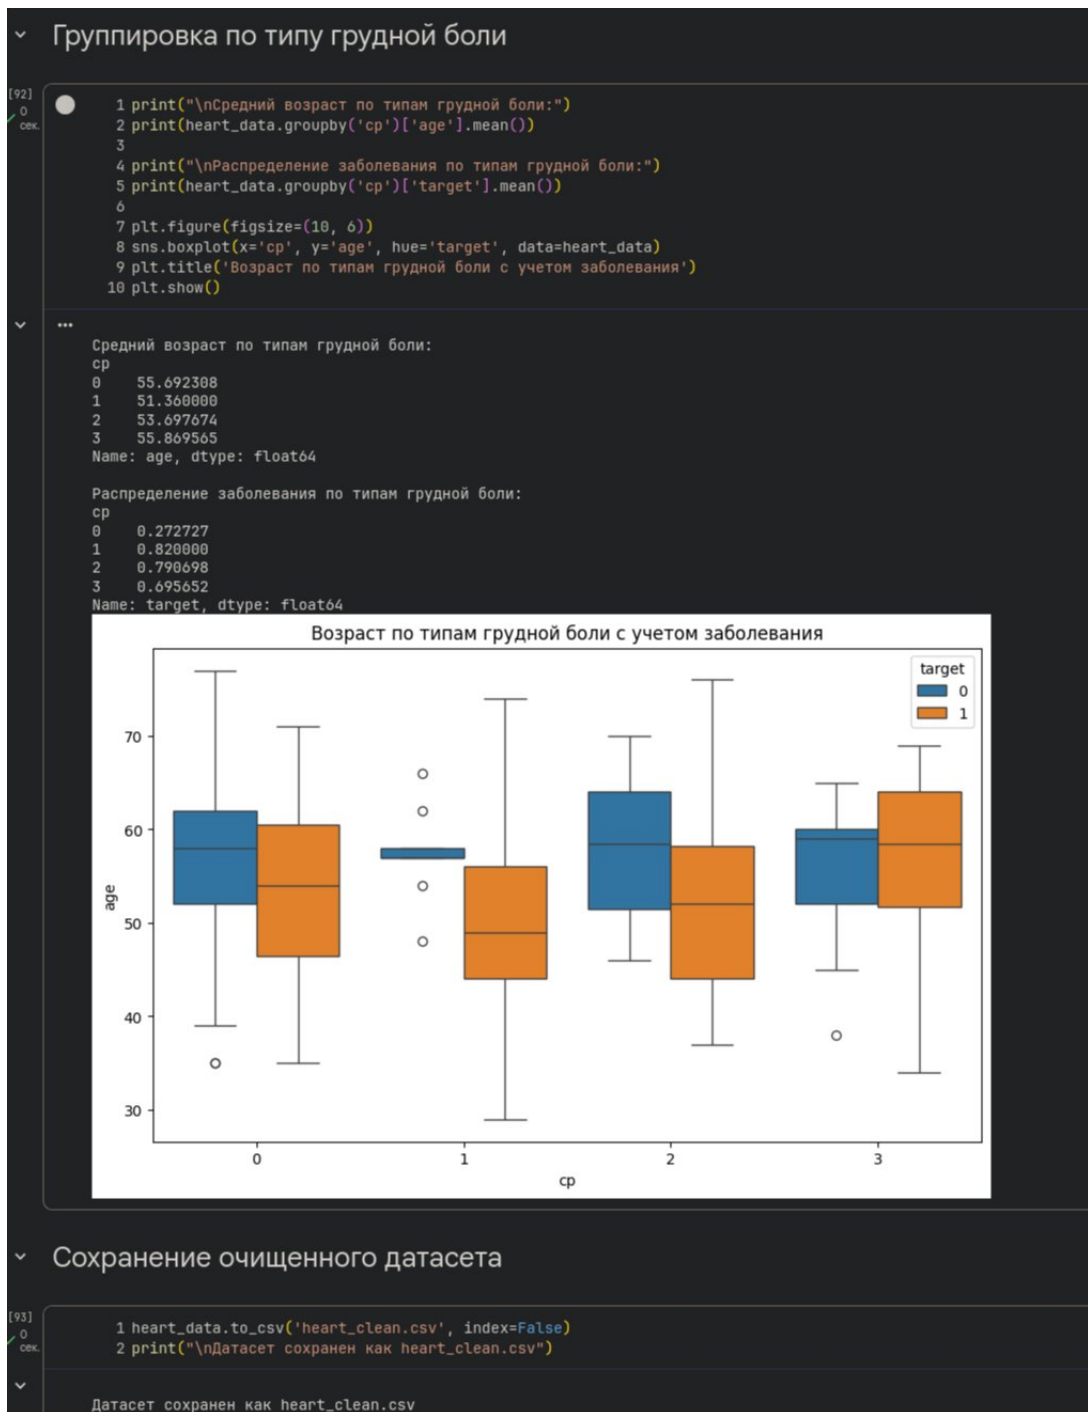


Рисунок 12 – Группировка по типу грудной боли и сохранение очищенного датасета

Заключение

В ходе практической работы были успешно освоены методы разведочного анализа данных (EDA) с применением библиотек pandas, matplotlib и seaborn.

Ключевые итоги:

Предобработка данных: Реализованы алгоритмы очистки признаков (runtime, gross_earn) от нечисловых символов с помощью регулярных выражений и корректной обработки пропусков. Это обеспечило приведение данных к форматам, пригодным для математического анализа.

Статистические инсайты:

Выявлена сильная правосторонняя асимметрия в распределении доходов: медиана оказалась гораздо более информативным показателем «типичного» успеха, чем среднее значение, искаженное выбросами.

Установлено отсутствие линейной связи между продолжительностью фильма и его кассовыми сборами.

Обнаружено, что возрастной рейтинг влияет на доходность: фильмы класса «U» показали наибольшую медианную прибыль, хотя чаще всего снимаются фильмы класса «15».

Визуализация: Отработаны навыки построения и интерпретации гистограмм, диаграмм «ящик с усами» (boxplot) и матриц рассеяния для выявления аномалий и паттернов.

Дополнительно был проведен самостоятельный анализ медицинского датасета Heart Disease UCI, что позволило закрепить навыки поиска факторов риска заболеваний.

Общий вывод: Разведочный анализ является критически важным этапом работы с данными. Он позволяет не только оценить качество датасета и очистить его от ошибок, но и сформулировать обоснованные гипотезы перед построением сложных прогнозных моделей.