

ПЕРВОЕ ВЫСШЕЕ ТЕХНИЧЕСКОЕ УЧЕБНОЕ ЗАВЕДЕНИЕ РОССИИ



**МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ
ФЕДЕРАЦИИ**

**федеральное государственное бюджетное образовательное учреждение высшего
образования**

**САНКТ-ПЕТЕРБУРГСКИЙ ГОРНЫЙ УНИВЕРСИТЕТ ИМПЕРАТРИЦЫ
ЕКАТЕРИНЫ II**

Кафедра информатики и компьютерных технологий

ПРАКТИЧЕСКАЯ РАБОТА №5

По дисциплине: Практические навыки и опыт анализа данных с помощью

Python

(наименование учебной дисциплины согласно учебному плану)

Тема работы: Статистические методы и модели

Выполнил: студент гр.

ИТ-25-3 (ИАС-25-1)

(шифр группы)

(подпись)

Черников В.М.

(Ф.И.О.)

Оценка: _____

Дата: _____

Проверил

руководитель работы:

доцент

(должность)

(подпись)

Кочнева А.А.

(Ф.И.О.)

Санкт-Петербург 2026

Введение

Практическая работа посвящена применению статистических методов и моделей для анализа рынка аренды жилья. В современных экономических условиях понимание факторов, влияющих на ценообразование в сфере недвижимости, имеет высокую практическую значимость как для арендодателей, стремящихся установить конкурентоспособные цены, так и для арендаторов, ищущих оптимальные предложения.

Цель работы – формирование навыков комплексного статистического анализа данных с использованием различных методов описательной и инференциальной статистики, корреляционного и регрессионного анализа.

В ходе работы решаются следующие задачи:

- проведение описательного анализа и визуализации распределений ключевых переменных;
- проверка статистических гипотез о влиянии категориальных признаков на стоимость аренды;
- оценка взаимосвязей между количественными показателями с помощью корреляционного анализа;
- построение парной и множественной регрессионных моделей для прогнозирования цены;
- формулировка практических рекомендаций для участников рынка аренды.

Комплексный подход, сочетающий теоретические знания и практическое применение инструментов Python (pandas, scipy, sklearn, statsmodels), позволяет получить обоснованные выводы и повысить качество принимаемых решений.

Этап 1

Повторим код, представленный в практической работе и проанализируем его (см Рисунки 1 – 4):

```
[1] 1 import numpy as np
    2 import pandas as pd
    3 import matplotlib.pyplot as plt
    4 import scipy.stats as stats
    5 import seaborn as sns
    6 import sklearn.linear_model as lm
    7 import statsmodels.api as sm
    8 import statsmodels.formula.api as smf
    9
   10 # Настройка отображения и отключение предупреждений
   11 pd.options.display.max_rows = 8
   12 import warnings
   13 warnings.filterwarnings('ignore')
   14
   15 print("Библиотеки успешно импортированы!")
```

Библиотеки успешно импортированы!

```
[2] 1 df = pd.read_csv("App_Rent.csv", sep=';')
    2 df.head()
```

Показать скрытые выходные данные

Далее: [New interactive sheet](#)

```
[3] 1 df.info()
```

Показать скрытые выходные данные

```
[4] 1 plt.figure(figsize=(12, 5))
    2
    3 plt.subplot(1, 2, 1)
    4 df['rent'].hist(bins=8, color='skyblue', edgecolor='black')
    5 plt.title('Распределение цены аренды (rent)')
    6 plt.xlabel('Цена')
    7 plt.ylabel('Частота')
    8
    9 plt.subplot(1, 2, 2)
   10 df['s'].hist(bins=8, color='lightgreen', edgecolor='black')
   11 plt.title('Распределение площади (s)')
   12 plt.xlabel('Площадь')
   13 plt.ylabel('Частота')
   14
   15 plt.tight_layout()
   16 plt.show()
```

Показать скрытые выходные данные

Рисунок 1 – Google Colab

```
[5] 0 сек.
1 # Основные статистики
2 print("--- Описательные статистики ---")
3 display(df.drop(['floor', 'walls', 'furniture', 'district'], axis=1).describe())
4
5 print("\nСредние значения:")
6 display(df[['rent', 's']].mean())
7
8 print("\nСтандартное отклонение:")
9 display(df[['rent', 's']].std())
10
11 print("\nКоэффициент асимметрии (Skewness):")
12 display(df[['rent', 's']].skew())
13
14 print("\nКоэффициент эксцесса (Kurtosis):")
15 display(df[['rent', 's']].kurtosis())
16
17 # Проверка нормальности (Шапиро-Уилка)
18 print("\n--- Тест Шапиро-Уилка на нормальность ---")
19 print("Rent p-value:", stats.shapiro(df['rent'])[1])
20 print("Area (s) p-value:", stats.shapiro(df['s'])[1])
21 print("Вывод: p < 0.05, распределения НЕ нормальные.")

... Показать скрытые выходные данные

[6] 1 сек.
1 print("Средняя цена по типу стен:")
2 display(df.groupby('walls')[['rent']].mean())
3
4 plt.figure(figsize=(6, 6))
5 sns.boxplot(x='walls', y='rent', data=df)
6 plt.title('Boxplot: Цена в зависимости от типа стен')
7 plt.show()
8
9 # Проверка нормальности внутри групп и U-тест Манна-Уитни
10 df_w0 = df[df['walls']==0]['rent']
11 df_w1 = df[df['walls']==1]['rent']
12
13 print("Shapiro walls=0:", stats.shapiro(df_w0)[1])
14 print("Shapiro walls=1:", stats.shapiro(df_w1)[1])
15
16 stat, p_val = stats.mannwhitneyu(df_w0, df_w1)
17 print(f"Mann-Whitney U-test: p-value = {p_val:.4f} (различия значимы, если p < 0.05)")

... Показать скрытые выходные данные

[8] 0 сек.
1 print("Средняя цена по наличию мебели:")
2 display(df.groupby('furniture')[['rent']].mean())
3
4 plt.figure(figsize=(6, 6))
5 sns.boxplot(x='furniture', y='rent', data=df)
6 plt.title('Boxplot: Цена в зависимости от наличия мебели')
7 plt.show()
8
9 df_f0 = df[df['furniture']==0]['rent']
10 df_f1 = df[df['furniture']==1]['rent']
11
12 stat, p_val = stats.mannwhitneyu(df_f0, df_f1)
13 print(f"Mann-Whitney U-test: p-value = {p_val:.4f}")

... Показать скрытые выходные данные
```

Рисунок 2 – Google Colab

```
[9]
✓ 0 сек.
1 print("Средняя цена и количество по районам:")
2 display(df.groupby('district')[['rent']].mean())
3 display(df.groupby('district')[['rent']].count())
4
5 plt.figure(figsize=(6, 6))
6 sns.boxplot(x='district', y='rent', data=df)
7 plt.title('Boxplot: Цена по районам (до очистки)')
8 plt.show()
9
10 # Поиск и удаление выброса
11 print("Выброс в районе 2:")
12 display(df.loc[(df['rent'] > 25000) & (df['district'] == 2)])
13 df = df.drop(df.index[[37]]) # Удаление строки 37
14 print("Выброс удален.")
15
16 # Тест Краскела-Воллиса (непараметрический аналог ANOVA для 3+ групп)
17 df_d1 = np.array(df[df['district']==1]['rent'])
18 df_d2 = np.array(df[df['district']==2]['rent'])
19 df_d3 = np.array(df[df['district']==3]['rent'])
20
21 stat, p_val = stats.mstats.kruskalwallis(df_d1, df_d2, df_d3)
22 print(f"Kruskal-Wallis H-test: p-value = {p_val:.4f}")

Показать скрытые выходные данные

[10]
✓ 0 сек.
1 # 1. Стены и площадь
2 print("Средняя площадь по типу стен:")
3 display(df.groupby('walls')[['s']].mean())
4 plt.figure(figsize=(6, 6))
5 sns.boxplot(x='walls', y='s', data=df)
6 plt.show()
7 print("Mann-Whitney (walls vs s):", stats.mannwhitneyu(df[df['walls']==0]['s'], df[df['walls']==1]['s'])[1])
8
9 # 2. Мебель и площадь
10 print("\nСредняя площадь по наличию мебели:")
11 display(df.groupby('furniture')[['s']].mean())
12 plt.figure(figsize=(6, 6))
13 sns.boxplot(x='furniture', y='s', data=df)
14 plt.show()
15 print("Mann-Whitney (furniture vs s):", stats.mannwhitneyu(df[df['furniture']==0]['s'], df[df['furniture']==1]['s'])[1])
16
17 # 3. Район и площадь
18 print("\nСредняя площадь по районам:")
19 display(df.groupby('district')[['s']].mean())
20 df_s_d1 = np.array(df[df['district']==1]['s'])
21 df_s_d2 = np.array(df[df['district']==2]['s'])
22 df_s_d3 = np.array(df[df['district']==3]['s'])
23 print("Kruskal-Wallis (district vs s):", stats.mstats.kruskalwallis(df_s_d1, df_s_d2, df_s_d3)[1])

... Показать скрытые выходные данные

[11]
✓ 2 сек.
1 # Матрицы корреляций
2 print("Корреляция Пирсона:")
3 display(df[['rent', 's', 'rooms']].corr(method='pearson'))
4
5 print("\nРанговая корреляция Спирмена:")
6 display(df[['rent', 's', 'rooms', 'floor']].corr(method='spearman'))
7
8 # Scatter plots (Диаграммы рассеяния)
9 df.plot("s", 'rent', kind="scatter", figsize=(8,5), title='Площадь vs Цена')
10 plt.show()
11 df.plot('rooms', 'rent', kind="scatter", figsize=(8,5), title='Комнаты vs Цена')
12 plt.show()
13
14 # Heatmaps (Тепловые карты)
15 plt.figure(figsize=(12, 5))
16 plt.subplot(1, 2, 1)
17 sns.heatmap(df[['rent', 's', 'rooms']].corr(), annot=True, cmap='coolwarm')
18 plt.title('Pearson Heatmap')
19
20 plt.subplot(1, 2, 2)
21 sns.heatmap(df[['rent', 's', 'rooms', 'floor']].corr(method='spearman'), annot=True, cmap='coolwarm')
22 plt.title('Spearman Heatmap')
23 plt.tight_layout()
24 plt.show()
25
26 # Точные p-value для корреляций
27 print("Pearson (rent & s):", stats.pearsonr(df['rent'], df['s']))
28 print("Pearson (rent & rooms):", stats.pearsonr(df['rent'], df['rooms']))
29 print("Spearman (rent & floor):", stats.spearmanr(df['rent'], df['floor']))

Показать скрытые выходные данные
```

Рисунок 3 – Google Colab


```
[12] 1 # 1. Стены и Мебель
✓ 0 2 WF = pd.crosstab(df['walls'], df['furniture'])
сек. 3 print("Таблица сопряженности (Стены и Мебель):")
4 display(WF)
5 sns.countplot(x=df['walls'], hue=df['furniture'])
6 plt.title('Стены vs Мебель')
7 plt.show()
8
9 chi2, prob, f, expected = stats.chi2_contingency(WF)
10 print(f"Chi2 test: Statistics={chi2:.2f}, df={f}, p-value={prob:.4f}\n")
11
12 # 2. Стены и Район
13 WD = pd.crosstab(df['walls'], df['district'])
14 print("Таблица сопряженности (Стены и Район):")
15 display(WD)
16 sns.countplot(x=df['district'], hue=df['walls'])
17 plt.title('Район vs Стены')
18 plt.show()
19
20 chi2, prob, f, expected = stats.chi2_contingency(WD)
21 print(f"Chi2 test: Statistics={chi2:.2f}, df={f}, p-value={prob:.4f}")

> Показать скрытые выходные данные

Далее: New interactive sheet New interactive sheet

[13] 1 # Визуализация с линией регрессии
✓ 2 2 sns.jointplot(x='s', y='rent', data=df, kind="reg", height=7)
сек. 3 plt.show()
4
5 # Модель sklearn
6 LR = lm.LinearRegression()
7 mod1 = LR.fit(df[['s']], df[['rent']])
8
9 print(f"Intercept (сдвиг): {mod1.intercept_}")
10 print(f"Coefficient (коэф. при площади): {mod1.coef_}")
11 print(f"R² (коэффициент детерминации): {mod1.score(df[['s']], df[['rent']]):.4f}")
12
13 # Статистический подход (OLS) через statsmodels
14 results1 = smf.ols('rent ~ s', data=df).fit()
15 print("\n--- OLS Summary (Statsmodels) ---")
16 display(results1.summary())

> ... Показать скрытые выходные данные


[14] 1 # Подготовка данных
✓ 0 2 X = df[['s', 'rooms', 'floor', 'walls', 'furniture']]
сек. 3 Y = df[['rent']]
4
5 # Обучение модели sklearn
6 mod_m = LR.fit(X, Y)
7 print("Коэффициенты множественной регрессии:")
8 for col, coef in zip(X.columns, mod_m.coef_[0]):
9     print(f"{col}: {coef:.2f}")
10 print(f"R² множественной модели: {mod_m.score(X, Y):.4f}")
11
12 # OLS Summary
13 resultsm = smf.ols('rent ~ s + rooms + floor + walls + furniture', data=df).fit()
14 print("\n--- OLS Summary (Multiple Regression) ---")
15 display(resultsm.summary())
16
17 # ПРОГНОЗ ДЛЯ НОВОЙ КВАРТИРЫ
18 # [площадь=54, комнаты=2, этаж=5, стены=1(кирпич), мебель=1(есть)]
19 x_new_app = [[54, 2, 5, 1, 1]]
20 y_new_app = mod_m.predict(x_new_app)
21
22 print(f"\n🧠 Прогноз цены для новой квартиры: {y_new_app[0][0]:.2f} руб.")
```

Рисунок 4 – Google Colab

Задание 1

На основе проведенного анализа должны быть сделаны выводы о влиянии различных факторов на цены на автомобили, а также выявлены ключевые тенденции и паттерны.

Решение представлено на Рисунках 5 – 13




```
Импорты и загрузка

[2]
0 сек.
1 import numpy as np
2 import pandas as pd
3 import matplotlib.pyplot as plt
4 import scipy.stats as stats
5 import seaborn as sns
6 import sklearn.linear_model as lm
7 import statsmodels.api as sm
8 import statsmodels.formula.api as smf
9 import warnings
10
11 warnings.filterwarnings('ignore')
12 pd.options.display.max_rows = 10
13
14 df = pd.read_csv("car_data1.csv")
15
16 print("Датасет успешно загружен!")
17 df.head()
```

Показать скрытые выходные данные

Далее: [New interactive sheet](#)

Рисунок 5 – Google Colab



```
Обзор данных и обработка пропусков

[3]
0 сек.
1 print("--- Информация о структуре датасета ---")
2 df.info()
3
4 print("\n--- Проверка пропусков ---")
5 display(df.isnull().sum())
6
7 # Обработка пропусков: заполнение медианой (более устойчива к выбросам)
8 df['Kms_Driven'].fillna(df['Kms_Driven'].median(), inplace=True)
9 df['Selling_Price'].fillna(df['Selling_Price'].median(), inplace=True)
10
11 print("\nПропуски успешно обработаны.")
```

Показать скрытые выходные данные

Рисунок 6 – Google Colab




Рисунок 7 – Google Colab



Рисунок 8 – Google Colab


```

Сравнение цен (Коробка передач и Тип топлива)

1 # 1. Влияние коробки передач (Transmission)
2 print("Средняя цена по типу КПП:")
3 display(df.groupby('Transmission')['Selling_Price'].mean())
4
5 plt.figure(figsize=(6, 5))
6 sns.boxplot(x='Transmission', y='Selling_Price', data=df)
7 plt.title('Цена в зависимости от КПП')
8 plt.show()
9
10 # Тест Манна-Уитни (т.к. распределение цены не нормальное)
11 manual = df[df['Transmission'] == 'Manual']['Selling_Price']
12 auto = df[df['Transmission'] == 'Automatic']['Selling_Price']
13 stat, p_val = stats.mannwhitneyu(manual, auto)
14 print(f"Мann-Whitney U-test (Transmission): p-value = {p_val:.4f} (различия значимы, если p < 0.05)\n")
15
16 # 2. Влияние типа топлива (Fuel_Type)
17 print("Средняя цена по типу топлива:")
18 display(df.groupby('Fuel_Type')['Selling_Price'].mean())
19
20 plt.figure(figsize=(8, 5))
21 sns.boxplot(x='Fuel_Type', y='Selling_Price', data=df)
22 plt.title('Цена в зависимости от типа топлива')
23 plt.show()
24
25 # Тест Краскела-Уоллиса (ANOVA для непараметрических данных, >2 групп)
26 groups = [group['Selling_Price'].values for name, group in df.groupby('Fuel_Type')]
27 stat, p_val = stats.kruskal(*groups)
28 print(f"Kruskal-Wallis H-test (Fuel_Type): p-value = {p_val:.4f}")

```

Рисунок 9 – Google Colab



Рисунок 10 – Google Colab



Рисунок 11 – Google Colab




Рисунок 12 – Google Colab

Вывод

Построенная OLS-модель объясняет 88.2% вариации целевой переменной Selling_Price ($R^2 = 0.882$), что является отличным показателем для экономических данных. Значение F-статистики (271.2, p-value ≈ 0) подтверждает статистическую значимость модели в целом — выявленные закономерности не случайны.

Рисунок 13 – Google Colab

Заключение

В ходе практической работы были успешно сформированы навыки комплексного статистического анализа данных с применением различных методов описательной и инференциальной статистики, корреляционного и регрессионного анализа на примере двух реальных задач: анализа рынка аренды жилья и рынка продаж автомобилей.

Применение комплексного подхода, сочетающего описательную статистику, проверку гипотез и регрессионное моделирование, позволяет:

- Выявлять скрытые закономерности в данных и отличать реальные зависимости от случайных флуктуаций
- Количественно оценивать влияние различных факторов на целевые показатели
- Строить прогнозные модели для поддержки принятия решений